

RELATÓRIO EXECUTIVO DE PROJETO: IA E ANALYTICS

Curso: MBA em Inteligência Artificial e Analytics Aplicados a Negócios — FGV

Disciplina: Redes Neurais Aplicadas a Negócios

Projeto: Otimização de Precificação Dinâmica e Yield Management Aéreo com IA Neuro-Simbólica

Autor: Marcio Mizumoto Takahara (marciomt87-ops)

Professor: Marco Fidos

DOCUMENTO 1: PROMPT DE ENGENHARIA DO AGENTE DE PRECIFICAÇÃO E YIELD MANAGEMENT

1. Objetivo (Finalidade & Público-alvo)

- **Finalidade:** Atuar como o motor central de tomada de decisão algorítmica de preços para o e-commerce de uma companhia aérea, combinando a estimativa de probabilidade de conversão da Rede Neural com regras de governança de Yield Management para calcular a tarifa ótima de cada assento.
- **Público-alvo:** Diretoria de Revenue Management, Comitê Executivo de Pricing e Sistemas de e-Commerce (APIs de checkout em tempo real).

2. Papel (Role / Tom / Autoridade)

- **Persona:** Chief Revenue Officer & AI Yield Specialist autônomo, com vasta experiência em microeconomia aplicada, elasticidade de demanda e revenue management aeronáutico.

- **Tom:** Analítico, quantitativo, objetivo, estritamente orientado à maximização de margem/receita e conformidade regulatória.
- **Limites de Atuação:** O agente não pode sugerir tarifas abaixo do custo marginal base estabelecido (R\$ 400,00) e não deve alterar as regras de governança corporativa sem autorização executiva.

3. Contexto & Dados (Fontes / O que NÃO usar)

- **Dados de Entrada Permitidos (Em Tempo Real):**
 - dias_ate_decolagem (inteiro: 1 a 90)
 - taxa_ocupacao_atual (float: 0.10 a 0.95)
 - preco_concorrente (float em R\$: 300,00 a 1.500,00)
 - historico_buscas_24h (inteiro: 50 a 1.000 buscas)
 - dia_da_semana (inteiro: 0 a 6)
 - custo_base_minimo (float em R\$, padrão: R\$ 400,00)
 - preco_teto_maximo (float em R\$, padrão: R\$ 2.000,00)
- **O que NÃO usar / Proibições:**
 - Proibido inventar dados de concorrência ou premissas macroeconômicas não fornecidas no payload.

- Proibido utilizar dados pessoais ou demográficos dos passageiros (aderência estrita à LGPD e não-discriminação tarifária pessoal).

4. Tarefa (Instrução Explícita)

Para cada requisição de cotação de passagem aérea, execute sequencialmente:

1. **Percepção e Validação:** Validar os dados de contexto da busca de voo.
2. **Avaliação da Elasticidade (Rede Neural):** Avaliar a probabilidade prevista de conversão $\hat{P}(\text{Compra} \mid p)$ para toda a grade de preços candidatos $p \in [\text{custo_base}, \text{preco_teto}]$.
3. **Avaliação da Função Objetivo:** Calcular a Receita Esperada:
$$E[\text{Receita}(p)] = p \times \hat{P}(\text{Compra} \mid p).$$

4. Aplicação dos Guardrails de Yield Management:

- *Regra de Escassez (Voo Próximo):* Se $\text{ocupacao} \geq 80\%$ e $\text{dias} \leq 7$, elevar o piso tarifário para $\max(\text{custo_base}, \text{preco_concorrente} \times 0.98, \text{R\$ } 850,00)$.
- *Regra de Spoilage (Assento Vazio):* Se $\text{ocupacao} < 40\%$ e $\text{dias} \leq 15$, limitar o preço teto para estimular volume.
- *Regra de Defesa Competitiva:* Se $\text{preco_concorrente} < 450$ e $\text{ocupacao} < 70\%$, limitar o spread de preço para defender market share.

- *Regra de Surge de Demanda*: Se buscas ≥ 800 , elevar o piso da margem em +25%.

5. **Decisão e Emissão de Parecer**: Selecionar o preço ótimo viável que maximiza $E[\text{Receita}]$ e retornar o parecer executivo estruturado em JSON.

DOCUMENTO 2: ARQUITETURA E PLANEJAMENTO DO PROJETO DE PRECIFICAÇÃO DINÂMICA

1. Visão Geral do Problema e Objetivo de Negócio

O Problema de Negócio

No setor aéreo, o assento de uma aeronave é um bem **altamente perecível**: um assento vazio no momento da decolagem representa perda irreversível de receita (*spoilage*). Por outro lado, vender bilhetes antecipadamente por tarifas muito baixas causa diluição de margem e impede a captura de viajantes corporativos de última hora, dispostos a pagar tarifas premium (*spill / dilution*).

A **precificação estática ou baseada em regras manuais rígidas** não acompanha as oscilações de mercado em tempo real, gerando perda constante de margem de contribuição e ineficiência operacional.

Análise da Necessidade Real de IA vs. Regras Determinísticas

Embora sistemas puramente baseados em regras (tabelas estáticas *if-then*) consigam aplicar bloqueios de segurança, eles falham ao tentar estimar superfícies contínuas de elasticidade-preço. A combinação de uma **Rede Neural Preditiva** (que aprende a sensibilidade do consumidor frente a múltiplas variáveis simultâneas) com um **Agente Prescritivo de Regras** permite capturar valor em cenários não lineares onde uma regra fixa causaria subprecificação ou perda de vendas.

Métricas de Sucesso de Negócio e Impacto Projetado

- **Incremento no RASK (*Revenue per Available Seat Kilometer*):** Projeção de **+3% a +6%** (equivalente a uma receita incremental estimada de **R\$ 45.000,00 por rota/mês** em uma malha simulada com 10 rotas ativas).
- **Otimização do *Load Factor* (Taxa de Ocupação):** Aumento de até **8%** na ocupação de voos em janelas de baixa demanda (*spoilage mitigation*).
- **Agilidade Operacional:** Redução do tempo de reação a oscilações da concorrência e picos de demanda de **horas para milissegundos (< 100ms)**.

2. Coleta, Preparação de Dados e Mapeamento de Features

Fontes de Dados

- **Sistema de Vendas/Checkout (e-Commerce API):** Histórico de buscas, conversões e desistências por rota.
- **Global Distribution Systems (GDS) & Web Scrapers:** Preços atualizados praticados pelos concorrentes diretos na mesma rota/horário.
- **Inventory Management (GDS / PSS):** Taxa de ocupação da aeronave em tempo real e capacidade total.

Tratamento de Dados e Prevenção de Leakage

- **Valores Nulos & Outliers:** Tratamento e remoção de buscas automatizadas (*bots* de varredura) com frequências acima do percentil 99.
- **Engenharia de Features:**
 - `dias_ate_decolagem`: Dias restantes até a data do voo.

- taxa_ocupacao_atual: Assentos ocupados / Capacidade total da aeronave.
- preco_concorrente: Tarifa praticada pelo principal concorrente.
- historico_buscas_24h: Volume de pesquisas na rota nas últimas 24h (indicador de *surge*).
- preco_ofertado: Valor testado para a passagem.

3. Estratégia de Viabilidade Econômica e ROI

Para validar a viabilidade econômica do projeto frente a abordagens tradicionais, estimou-se a estrutura completa de custos de desenvolvimento (CAPEX) e operação (OPEX) contra o retorno incremental esperado:

Tabela Financeira de Custos e Retorno Esperado (Estimativa Anual)

Categoria Financeira	Descrição do Componente	Custo / Valor Estimado (R\$)
CAPEX (Custo de Construção)	Engenharia de dados, pipelines GDS, treino do modelo MLP, desenvolvimento do Agente no Antigravity e testes em Shadow Mode	R\$ 35.000,00 <i>(investimento único)</i>
OPEX (Custo de Sustentação Anual)	Infraestrutura Cloud (API REST FastAPI/Docker em AWS/GCP), monitoramento MLOps e retraining semanal automatizado	R\$ 30.000,00 (R\$ 2.500,00 / mês)
Custo Total do Projeto (Ano 1)	CAPEX + OPEX Anual	R\$ 65.000,00

Categoria Financeira	Descrição do Componente	Custo / Valor Estimado (R\$)
Retorno Anual Projetado (Benefício)	Ganho incremental de +4,5% no RASK em 10 rotas ativas (R\$ 45.000,00 / rota / mês)	R\$ 540.000,00 / ano

Cálculo de ROI e Payback

$$ROI = \frac{\text{Retorno Anual} - \text{Custo Total Anual}}{\text{Custo Total Anual}} = \frac{540.000 - 65.000}{65.000} \times 100 \approx \mathbf{730,77\%}$$

- **Payback Estimado: ~1,4 meses** após a entrada oficial em produção.
- **Justificativa Econômica:** O ganho financeiro supera expressivamente os custos de infraestrutura e sustentação do modelo profundo, tornando a solução altamente atrativa sob a ótica de negócios.

4. Estratégia de Bases, Split e Seleção de Algoritmos (Comparações Empíricas)

Metodologia de Split e Prevenção de Vazamento

- **Data Split:** 80% Treino (3.200 amostras) / 20% Teste (800 amostras) com amostragem estratificada.
- **Prevenção de Data Leakage:** O dimensionamento e padronização das variáveis via `StandardScaler()` foram ajustados (*fit*) exclusivamente no conjunto de treino e aplicados (*transform*) ao teste.

Comparativo Empírico: ML Tradicional vs. Redes Neurais (Executado no Mesmo Split)

Conforme prometido na fase de planejamento, executou-se e avaliou-se um modelo **Baseline de Regressão Logística** diretamente no código contra a **Rede Neural MLP**:

Modelo / Algoritmo	Acurácia	ROC-AUC	Log Loss	Complexidade Computacional	Justificativa de Escolha
Regressão Logística (Baseline)	62,45%	0,6612	0,6420	Baixíssima (Instantânea)	Não captura interações não lineares entre ocupação, dias e concorrência.
Rede Neural MLP (64x32, ReLU, Dropout)	66,88%	0,7181	0,5810	Média (~20 épocas de treino)	Vencedor: Gera superfícies de decisão suaves essenciais para interpolação contínua pelo agente.

- **Validação de Robustez (Múltiplas Seeds):** Para confirmar que o desempenho superior do modelo profundo não decorreu de sorte de amostragem (seed=42), a MLP foi submetida a testes com 3 sementes aleatórias distintas (10, 42, 100), mantendo um **AUC-ROC médio de $0,7175 \pm 0,0012$** , comprovando a estabilidade e robustez estatística do modelo.

5. Estratégia de Treinamento, Otimização e MLOps

Arquitetura e Configuração da Rede Neural

- **Entrada:** 6 variáveis contextuais.

- **Camadas Ocultas:** Camada 1 com 64 neurônios (ReLU) + Dropout (0.20); Camada 2 com 32 neurônios (ReLU) + Dropout (0.20).
- **Camada de Saída:** 1 neurônio (Sigmoid) para estimar a probabilidade de compra $P(\text{Compra} | p)$.
- **Compilação:** Otimizador Adam ($lr = 0.001$), perda binary_crossentropy, métrica accuracy.

Estratégia de MLOps: Deploy e Limiares Numéricos de Alerta

- **Arquitetura de Implantação:** API REST desenvolvida em FastAPI, empacotada em Docker e orquestrada para responder requisições em menos de 100ms. Retreinamento automatizado programado para ciclos semanais.
- **Gatilho Numérico de Data Drift (Teste Kolmogorov-Smirnov):** Calculado diariamente sobre a distribuição de preco_concorrente e historico_buscas_24h. Se a estatística $KS > 0,15$ com $p\text{-valor} < 0,05$ por mais de 3 dias consecutivos, dispara-se um **retreinamento emergencial fora do ciclo semanal**.
- **Gatilho Numérico de Concept Drift (Desvio de Conversão Real):** Monitoramento semanal do desvio absoluto entre a probabilidade de conversão prevista $\hat{P}$ e a taxa de conversão real observada nos voos. Se o desvio absoluto for $> 5,0$ **pontos percentuais** por 2 semanas consecutivas, a API reverte temporariamente para o modelo baseline e aciona a equipe para revisão manual de Revenue Management.

6. Declaração de Limitações do Trabalho e Roadmap

Declaração de Limitações Técnicas

- **Massa de Dados Sintética:** O dataset de 4.000 amostras utilizado neste trabalho foi gerado sinteticamente a partir de uma função logística pré-

definida. Embora ideal para validar a arquitetura neuro-simbólica e a integração do agente no AntigraVity, os ganhos percentuais de receita reportados não possuem respaldo em dados históricos reais e exigem validação empírica.

- **Simplificação Microeconômica:** Variáveis exógenas como volatilidade cambial, variação no preço do combustível de aviação (QAV) e sazonalidade de feriados prolongados não foram incorporadas nesta versão do modelo.

Roadmap de Implantação

1. **Validação em *Shadow Mode* (Modo Espelho):** Executar a solução em paralelo ao sistema legado por 30 dias sem alterar as tarifas finais do e-commerce, avaliando a precisão das probabilidades previstas contra as conversões reais.
2. **Testes A/B em Produção:** Implementar o agente em 2 rotas de teste (50% do tráfego precificado por IA vs. 50% pelo modelo legado) para apuração exata do RASK incremental.
3. **Adição de Feature Store:** Integrar Snowflake/Feast para consulta de dados agregados com baixíssima latência (< 20ms).